

Hijerarhijska klasifikacija biljnih bolesti korišćenjem dubokih neuronskih mreža

Marija Tadić, E9 12/2024
Fakultet tehničkih nauka, Univerzitet u Novom Sadu
Master studije - Mašinsko učenje i veštačka inteligencija
Predmet: Neuronske mreže

Sažetak—Rana i automatska detekcija biljnih bolesti sa fotografija listova može značajno ubrzati dijagnostiku u poljoprivredi. U ovom radu poredimo *hijerarhijski* pristup klasifikaciji - u kome prvi model prepoznaje vrstu biljke, a zatim poseban model po vrsti prepoznaje bolest - sa *flat* pristupom koji direktno klasifikuje svih 38 kombinacija (vrsta, bolest). Eksperimenti su izvedeni na skupu PlantVillage (54.305 slika, 14 vrsta, 38 klasa), koji je neuravnotežen na oba nivoa hijerarhije. Pošto skup nije balansiran, kao primarnu metriku koristimo *makro F1*, a tačnost (accuracy) prijavljujemo samo kao sporednu. Najbolji *flat* model (ResNet-50) postiže *makro F1* od 0,9843 na test skupu, dok *hijerarhijski* pristup postiže 0,9741 - dakle *hijerarhija ne donosi poboljšanje*, već blago zaostaje. Analizom propagacije greške pokazujemo da 21,1% grešaka *hijerarhije* potiče od pogrešno prepoznate vrste, što je nepopravljiv izvor greške koji *flat* model nema. Konačno, kroz Grad-CAM vizualizaciju i diskusiju o pristrasnosti na pozadinu (*background bias*) razmatramo zašto visoke vrednosti metrika na PlantVillage skupu ne garantuju upotrebljivost u realnim uslovima.

Glavne reči—klasifikacija biljnih bolesti, *hijerarhijska* klasifikacija, konvolucijske neuronske mreže, transfer learning, neuravnoteženi podaci, *makro F1*, PlantVillage

I. UVOD

Biljne bolesti su jedan od glavnih uzročnika gubitka prinosa i kvaliteta useva. Klasična dijagnostika zahteva iskusne stručnjake i vremenski je zahtevna, dok automatska detekcija metodama računarskog vida može omogućiti bržu i dostupniju dijagnostiku, uključujući i terensko skeniranje na uređajima ograničenih resursa.

Cilj ovog rada je razvoj i evaluacija sistema za automatsku klasifikaciju biljnih bolesti sa fotografija listova primenom dubokih konvolucijskih neuronskih mreža. Posebno ispitujemo *hijerarhijski* pristup: kompleksan problem sa 38 klasa deli se na dva jednostavnija zadatka - prepoznavanje vrste biljke (nivo 1) i, unutar prepoznate vrste, prepoznavanje tipa bolesti (nivo 2). Pretpostavka je da ovakva dekompozicija može poboljšati interpretabilnost i, eventualno, performanse. Da bismo proverili tu pretpostavku, kao referentnu tačku implementiramo *flat* klasifikator sa 38 klasa, te eksplicitno poredimo dva pristupa.

Glavni doprinosi rada su: (1) implementacija i poređenje *flat* i *hijerarhijskog* pristupa pod istim uslovima; (2) evaluacija prilagođena neuravnoteženom skupu, sa *makro F1* kao primarnom metrikom; (3) kvantifikacija *propagacije greške* u *hijerarhiji*; i (4) kritička diskusija o pristrasnosti na pozadinu i o tome zašto visoke metrike na PlantVillage skupu treba tumačiti sa oprezom.

II. SRODNI RADOVI

Mohanty i saradnici [1] prvi su primenili duboke mreže (AlexNet, GoogLeNet) na PlantVillage skup i postigli tačnost preko 99%, ali su uočili da performanse naglo opadaju na slikama snimljenim van kontrolisanih uslova. Ferentinos [2] proširuje ovaj pravac na veći broj arhitektura i klasa, potvrđujući visoku tačnost na laboratorijskim slikama. Too i saradnici [3] poredi fino podešavanje (*fine-tuning*) više arhitektura, dok Mohameth i saradnici [4] analiziraju ekstrakciju obeležja naspram finog podešavanja. Noyan [5] kritički ukazuje na *pristrasnost na pozadinu*: zbog gotovo uniformne pozadine po klasi, modeli mogu naučiti pozadinu umesto same lezije, što objašnjava slabu generalizaciju na terenske slike. Naš rad se nadovezuje na ovu kritiku: pored poređenja arhitektura i pristupa, eksplicitno merimo propagaciju greške i koristimo Grad-CAM [6] za vizuelnu analizu na šta model obraća pažnju.

III. METODOLOGIJA

A. Skup podataka i podela

Korišćen je PlantVillage skup (*color* verzija), sa 54.305 RGB slika listova razvrstanih u 38 klasa koje predstavljaju kombinaciju vrste biljke i bolesti, raspoređenih u 14 biljnih vrsta. Skup je *neuravnotežen* na oba nivoa: odnos najveće i najmanje klase iznosi približno 48,9:1 na nivou vrste i 36,2:1 na nivou bolesti. Dodatno, 5 od 14 vrsta ima samo jednu klasu (zdravo stanje), pa su za njih klasifikatori bolesti trivijalni.

Skup je podeljen na trening, validacioni i test deo u odnosu 70:15:15 primenom *stratifikovane* podele (uz fiksni seed 42), čime se očuvava raspodela klasa u svakom delu. Podela je perzistirana u CSV datotekama i nikada se ne regeneriše, čime se obezbeđuje reproducibilnost. Rezultujuće veličine su 38.013 (trening), 8.146 (validacija) i 8.146 (test) slika.

B. Pretprocesiranje i augmentacija

Sve slike su skalirane na 224×224 piksela i normalizovane statistikom ImageNet skupa. Nad trening skupom primenjena je *agresivna* augmentacija (slučajno isecanje i skaliranje, horizontalno i vertikalno preslikavanje, rotacije, affine i perspektivne transformacije, promene boje/osvetljenja, te slučajno brisanje regiona - *random erasing*). Agresivna augmentacija je namerna mera protiv pristrasnosti na pozadinu: cilj je primorati model da se oslanja na teksturu lista i lezije, a ne na uniformnu

pozadinu. Nad validacionim i test skupom *ne* primenjuje se augmentacija.

C. Modeli

Implementirana su tri tipa modela:

- **Baseline CNN** treniran od nule (4 konvolucijska bloka sa batch normalizacijom, globalnim pooling-om i dropout-om, $\approx 1,3M$ parametara) - služi kao referentna tačka “od nule”.
- **ResNet-50** sa ImageNet pretreniranim težinama (transfer learning), uz fino podešavanje poslednje dve etape i klasifikacionog sloja.
- **EfficientNet-B0** (podržan u implementaciji kao lakša alternativa); glavni izveštaji odnose se na ResNet-50 kao reprezentativan transfer model.

Hijerarhijski sistem se sastoji od jednog modela za vrstu (14 klasa) i rečnika modela za bolest - po jednog za svaku od 9 netrivialnih vrsta; pet vrsta sa jednom klasom rutira se direktno. U fazi predikcije, izlaz modela za vrstu bira odgovarajući model za bolest.

D. Treniranje i tretiranje neuravnoteženosti

Modeli su trenirani optimizatorom AdamW (varijanta Adama sa razdvojenom regularizacijom težina), uz kosinusni raspored stope učenja, rano zaustavljanje (*early stopping*) i čuvanje najboljeg modela prema *validacionom makro F1* (a ne prema gubitku). Za tretiranje neuravnoteženosti koristi se *ponderisana* unakrsna entropija (*weighted cross-entropy*), sa težinama izvedenim iz frekvencija klasa u trening skupu; implementacija takođe podržava *focal* gubitak [7] i ponderisano uzorkovanje. Treniranje je izvedeno na Kaggle GPU (Tesla T4), a razvoj koda lokalno.


E. Evaluacija

Pošto skup nije balansiran, tačnost (accuracy) nije reprezentativna metrika i prijavljuje se samo kao sporedna. Primarne metrike su: **makro F1** (tretira sve klase jednako), *ponderisani* F1, *balansirana tačnost*, te precision/recall po klasi i matrica konfuzije. Za hijerarhiju se računaju *end-to-end* metrike na finalnoj (vrsta, bolest) predikciji, kao i *propagacija greške* - udeo grešaka koje potiču od pogrešno prepoznate vrste.

IV. REZULTATI

A. Flat modeli

Na validacionom skupu, baseline CNN (od nule) postiže makro F1 od 0,9826, a ResNet-50 (transfer) 0,9882. Pretreniranje na ImageNet skupu donosi samo $\approx 0,5$ procentnih poena, što ukazuje da je zadatak na ovom skupu gotovo zasićen i da ga čak i jednostavna mreža od nule rešava skoro savršeno. Slika 1 prikazuje krive učenja.




Slika 1. Validacioni makro F1 po epohama (levo) i gubitak za ResNet-50 (desno).

B. Hijerarhija: nivoi

Model za vrstu (nivo 1) postiže makro F1 od 0,9974 na validaciji - prepoznavanje vrste je gotovo savršeno, što sugerise mali doprinos propagacije greške sa prvog nivoa. Klasifikatori bolesti (nivo 2) variraju po vrsti (Tabela I, Slika 2): od savršenih kod binarnih vrsta do najtežih - krompir (0,9047) i kukuruz (0,9467).

Tabela I
MAKRO F1 KLASIFIKATORA BOLESTI PO VRSTI (VALIDACIJA).

Vrsta	Broj bolesti	Makro F1
Cherry	2	1,0000
Strawberry	2	1,0000
Peach	2	0,9947
Pepper bell	2	0,9944
Grape	4	0,9935
Apple	4	0,9865
Tomato	10	0,9764
Corn	4	0,9467
Potato	3	0,9047




Slika 2. Makro F1 klasifikatora bolesti po vrsti; crvenom su označene najslabije (Potato, Corn).

C. Flat pristup naspram hijerarhije

Tabela II i Slika 3 prikazuju glavni rezultat na *test* skupu. Flat ResNet-50 postiže makro F1 od 0,9843, dok hijerarhija postiže 0,9741 - razlika je $-0,0102$ u korist flat pristupa. Isti trend važi i za ostale metrike.

Tabela II
FLAT NASPRAM HIJERARHIJSKOG PRISTUPA (TEST SKUP). MAKRO F1 JE PRIMARNA METRIKA; TAČNOST JE SPOREDNA.


Metrika	Flat	Hijerarhija	Δ
Makro F1	0,9843	0,9741	-0,0102
Ponderisani F1	0,9868	0,9821	-0,0047
Balansirana tačnost	0,9859	0,9813	-0,0046
Tačnost (sporedno)	0,9867	0,9820	-0,0047



Slika 3. Flat naspram hijerarhijskog pristupa na test skupu.

D. Propagacija greške

Na test skupu, model za vrstu je tačan u 99,62% slučajeva, a klasifikacija bolesti uz tačnu vrstu postiže makro F1 od 0,9815. Od ukupno 147 end-to-end grešaka hijerarhije, 31 potiče od pogrešne vrste (nepopravljivo), a 116 od pogrešne bolesti pri tačnoj vrsti. Dakle, 21,1% svih grešaka uzrokovano je prvim nivoom (Slika 4). Flat model nema ovaj kaskadni izvor greške, što objašnjava njegovu blagu prednost.




Slika 4. Izvori end-to-end grešaka hijerarhije.

E. Analiza grešaka

Matrica konfuzije flat modela (Slika 5) pokazuje izraženu dijagonalu uz greške koncentrisane među bolestima paradajza

i kukuruza. Najslabije klase po F1 su Tomato Early blight (0,89), Corn Cercospora/Gray leaf spot (0,91) i Tomato Late blight (0,94). Najčešća zabuna je između dve gljivične bolesti kukuruza; uočena je i *međuvrsna* zabuna - Potato Late blight predviđen kao Tomato Late blight - što odgovara činjenici da je reč o istoj bolesti na srodnim biljkama.



Slika 5. Matrica konfuzije flat ResNet-50 modela (test, normalizovano po redu = recall po klasi).


V. DISKUSIJA

A. Zašto hijerarhija ne pomaže

Iako intuitivno deluje da dekompozicija problema treba da pomogne, na ovom skupu hijerarhija blago zaostaje. Razlog je dvojak: (1) flat model već postiže $\approx 0,98$, pa je prostor za poboljšanje mali; i (2) hijerarhija uvodi dodatnu tačku otkaza - greške na nivou vrste su nepopravljive i čine petinu svih grešaka. Flat model zajednički modeluje (vrsta, bolest) i izbegava kaskadu. Ovo je validan rezultat: hijerarhijski pristup nije uvek opravdan.

B. Visoke metrike i pristrasnost na pozadinu

Vrednosti metrika na PlantVillage skupu su veoma visoke za sve modele, što je u skladu sa literaturom [1], [2]. Međutim, ove vrednosti ne treba tumačiti kao meru upotrebljivosti u praksi. PlantVillage slike su snimane u kontrolisanim uslovima, sa gotovo uniformnom pozadinom po klasi, pa model može naučiti pozadinu kao prečicu [5]. Grad-CAM analiza (Slika 6) pokazuje da model uglavnom obraća pažnju na tkivo lista, ali difuzno - ne precizno na leziju. Pošto list popunjava gotovo ceo kadar, pristrasnost na pozadinu se na ovim slikama teško direktno uočava; glavni rizik ostaje slaba generalizacija na terenske slike sa drugačijom pozadinom.



Slika 6. Grad-CAM mape flat modela: gde model “gleda”. Toplota je pretežno na listu, ali difuzna.

C. Ograničenja

Pored pristrasnosti na pozadinu, PlantVillage sadrži i *približne duplikate* (više snimaka istog lista), pa slučajna podela po slici može staviti slične primere i u trening i u test, čime se metrike dodatno naduvavaju. Konačno, sve metrike su merene na istom domenu (laboratorijske slike); validacija na nezavisnom terenskom skupu ostaje za budući rad.

D. Kada hijerarhija ipak ima smisla

Iako ne donosi bolju tačnost, hijerarhija nudi *interpretabilnost i modularnost*: jasno se vidi da li greška nastaje na nivou vrste ili bolesti, a pojedinačni klasifikatori se mogu nezavisno unapređivati (npr. ciljano za najteže vrste - krompir i kukuruz). To je kompromis između performanse i interpretabilnosti.

VI. ZAKLJUČAK

Uporedili smo flat i hijerarhijski pristup klasifikaciji biljnih bolesti na PlantVillage skupu, uz evaluaciju prilagođenu neuravnoteženim podacima. Flat ResNet-50 postiže makro F1 od 0,9843 naspram 0,9741 za hijerarhiju, pa hijerarhija *ne donosi poboljšanje*; analiza propagacije greške pokazuje da petina grešaka hijerarhije potiče od nivoa vrste. Najvažniji zaključak nije sama visoka tačnost - koja je očekivana i delom posledica svojstava skupa - već spoznaja da takve vrednosti precenjuju realnu upotrebljivost zbog pristrasnosti na pozadinu. Budući rad obuhvata validaciju na terenskim slikama, grupisanje približnih duplikata pri podeli, te ciljano unapređenje najtežih klasa.

LITERATURA

- [1] S. P. Mohanty, D. P. Hughes, and M. Salathé, “Using deep learning for image-based plant disease detection,” *Frontiers in Plant Science*, vol. 7, 1419, 2016.
- [2] K. P. Ferentinos, “Deep learning models for plant disease detection and diagnosis,” *Computers and Electronics in Agriculture*, vol. 145, pp. 311–318, 2018.
- [3] E. C. Too, L. Yujian, S. Njuki, and L. Yingchun, “A comparative study of fine-tuning deep learning models for plant disease identification,” *Computers and Electronics in Agriculture*, vol. 161, pp. 272–279, 2019.
- [4] F. Mohameth, C. Bingcai, and K. A. Sada, “Plant disease detection with deep learning and feature extraction using Plant Village,” *Journal of Computer and Communications*, vol. 8, no. 6, pp. 10–22, 2020.
- [5] M. A. Noyan, “Uncovering bias in the PlantVillage dataset,” *arXiv preprint arXiv:2206.04374*, 2022.
- [6] R. R. Selvaraju *et al.*, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proc. IEEE ICCV*, 2017, pp. 618–626.
- [7] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proc. IEEE ICCV*, 2017, pp. 2980–2988.
- [8] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE CVPR*, 2016, pp. 770–778.
- [9] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. ICML*, 2019, pp. 6105–6114.